

# Regressão e Regressão Logística

---

Carlos Diego Rodrigues

28 de outubro de 2021


Universidade Federal do Ceará

- Regressão: consiste em encontrar uma função que traduz as relações entre uma variável dependente (classe) e diversas variáveis independentes (atributos). Essa relação se traduz matematicamente como uma função e o tipo mais comum é a função **linear**.

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_1 x_1 + \cdots + \theta_n x_n = \sum_{j=0}^n \theta_j x_j = \theta^T x$$

- Método canônico na estatística
- Existem diversas formas de encontrar uma regressão linear, mas tipicamente utiliza-se o método de **mínimos quadrados**.

# Exemplo regressão



# Mínimos quadrados

- Neste método queremos minimizar o erro quadrático do modelo gerado em relação às observações presentes no conjunto de treinamento.

$$\min \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 = 2 \min \frac{1}{2} (h_{\theta}(x^i) - y^i)^2 = J(\theta)$$

- Isto pode ser feito através de um processo de otimização iterativo que atualiza um vetor tentativa  $\theta$  iterativamente até convergir para aquele que corresponde ao mínimo da expressão acima, na direção da derivada da função a ser otimizada.

$$\theta_j \leftarrow \theta_j - \alpha \frac{d}{d\theta_j} J(\theta)$$

- O fator  $\alpha$  é chamado taxa de aprendizado do método.

## Derivando e concluindo

- Derivando temos:

$$\begin{aligned}\frac{d}{d\theta_j} J(\theta) &= \frac{d}{d\theta_j} (h_{\theta}(x) - y)^2 \\ &= 2 \cdot \frac{1}{2} (h_{\theta}(x) - y) \cdot \frac{d}{d\theta_j} (h_{\theta}(x) - y) \\ &= (h_{\theta}(x) - y) \cdot \frac{d}{d\theta_j} \left( \sum_{k=1}^n \theta_k x_k - y \right) \\ &= (h_{\theta}(x) - y) x_j\end{aligned}$$

- Portanto podemos atualizar o valor de  $\theta$  fazendo

$$\theta_j \leftarrow \theta_j + \alpha (y^i - h_{\theta}(x^i)) x_j^i$$

- O algoritmo consiste portanto em repetir estas atualizações até que se obtenha a convergência desejada.

# Algoritmo Descida do gradiente

---

## Algorithm 1 Descida do gradiente

---

**Entrada:**  $X, Y$ : conjunto de atributos e classes

**Saída:**  $\theta$ : um modelo de regressão

- 1: Encontre um valor inicial para  $\theta$
  - 2: **repeat**
  - 3:   **for**  $i \leftarrow 1 \cdots m$  **do**
  - 4:     **for**  $j \leftarrow 1 \cdots n$  **do**
  - 5:        $\theta_j \leftarrow \theta_j + \alpha(y^i - h_{\theta}(x^i))x_j^i$
  - 6:   **until** convergência
  - 7: Retorna  $\theta$
-

# Explicação probabilística

- Podemos pensar que a resposta do modelo de regressão se relaciona aos dados originais através da expressão:

$$y^i = \theta^T x^i + \epsilon^i$$

onde os valores  $\epsilon^i$  são independentes e normalmente distribuídos ( $\epsilon^i \sim N(0, \sigma)$ ).

- Dessa forma, vamos considerar a distribuição de cada erro:

$$p(\epsilon^i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\epsilon^i)^2}{2\sigma^2}\right)$$

- Portanto:

$$p(y^i | x^i; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^i - \theta^T x^i)^2}{2\sigma^2}\right)$$

# Minimizando a verossimilhança

- Definindo a verossimilhança:

$$L(\theta) = \prod_{i=1}^m p(y^i | x^i; \theta)$$

- No entanto o produto é uma função difícil de trabalhar. Podemos tomar, contudo, o logaritmo desta função, cujo máximo é dado pelo mesmo argumento.
- Assim temos:

$$\begin{aligned} l(\theta) &= \log L(\theta) \\ &= m \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{\sigma^2} \cdot \frac{1}{2} \sum_{i=1}^m (y^i - \theta^T x^i)^2 \end{aligned}$$

- A conclusão é que minimizar o erro sob estas hipóteses é equivalente a encontrar o melhor  $\theta$  com o método de mínimos quadrados.




# Regressão logística

- Se ignorarmos o fato que  $y$  é uma variável binária poderíamos usar a regressão para os problemas de classificação.
- No entanto facilmente encontraríamos exemplos onde esse método funciona muito, pois os valores intermediários são difíceis de distinguir para uma função linear.
- Isto pode ser corrigido se utilizarmos uma função logística.

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + \exp(-\theta^T x)}$$

onde a função  $g$  é chamada função logística ou sigmoid.

# Exemplo regressão



## Derivando a função logística

- Para aplicarmos uma metodologia similar à anterior seria interessante conhecer a derivada da função  $g$ :

$$\begin{aligned}g'(z) &= \frac{d}{dz} \frac{1}{1 + e^{-z}} \\&= \frac{1}{(1 + e^{-z})^2} e^{-z} \\&= \frac{1}{1 + e^{-z}} \cdot \left(1 - \frac{1}{1 + e^{-z}}\right) \\&= g(z)(1 - g(z))\end{aligned}$$

- Vamos utilizar a mesma ideia da regressão linear para derivar um estimador interessante  $\theta$  para a verossimilhança do modelo logístico.

# Verossimilhança do modelo logístico

- Vamos supor que:

$$P(y = 1|x; \theta) = h_{\theta}(x)$$

$$P(y = 0|x; \theta) = 1 - h_{\theta}(x)$$

- Isto pode ser transformado em uma função de distribuição:

$$p(y|x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

- Definindo a função de verossimilhança:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^m p(y^i|x^i; \theta) \\ &= \prod_{i=1}^m (h_{\theta}(x^i))^{y^i} (1 - h_{\theta}(x^i))^{1-y^i} \end{aligned}$$

# Otimizando o logaritmo

- Definindo o logaritmo da verossimilhança

$$\begin{aligned}l(\theta) &= \log L(\theta) \\&= \sum_{i=1}^m y^i \log h_{\theta}(x^i) + (1 - y^i) \log(1 - h_{\theta}(x^i))\end{aligned}$$

- Derivando a função  $l(\theta)$ :

$$\begin{aligned}\frac{d}{d\theta_j} l(\theta) &= \left( y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) \frac{d}{d\theta_j} g(\theta^T x) \\&= \left( y \frac{1}{g(\theta^T x)} - (1 - y) \frac{1}{1 - g(\theta^T x)} \right) g(\theta^T x) (1 - g(\theta^T x)) \frac{d}{d\theta_j} x \\&= (y(1 - g(\theta^T x)) - (1 - y)g(\theta^T x))x_j \\&= (y - h_{\theta}(x))x_j\end{aligned}$$

## Descida do gradiente para Regressão logística

- Podemos otimizar o valor de  $l(\theta)$  a partir do valor de sua derivada, fazendo

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} l(\theta)$$

- Encontramos portanto que a minimização da verossimilhança (e portanto a definição de um modelo) para a regressão logística pode ser obtida de forma semelhante àquela obtida na regressão linear, através de sucessivas atualizações do modelo  $\theta$ :

$$\theta_j \leftarrow \theta_j + \alpha(y^i - h_{\theta}(x^i))x_j$$

- Esta função é muito semelhante, porém não idêntica àquela encontrada para a regressão pois as funções  $h_{\theta}(x)$  são distintas.