

# Máquinas de vetor de suporte

---

Carlos Diego Rodrigues

14 de dezembro de 2021


Universidade Federal do Ceará

## Máquinas de vetor de suporte - SVM

- Máquinas de vetor de suporte estão entre os métodos mais populares e mais eficientes para problemas de classificação.
- Consiste em encontrar uma borda (ou margem) de classificação que separa exemplos de classes distintas.
- Qual a melhor margem separadora? Vetores de suporte.
- A partir de uma borda linear é possível encontrar outras bordas de maior complexidade que satisfaçam algumas condições na definição da função de borda.
- *Kernell tricks*


- Quando fazemos uma regressão logística, temos como resultado um modelo  $\theta$  de tal forma que ao aplicarmos a função sobre um exemplo  $x^i$ , o resultado  $h_{\theta}(x^i) \geq 0,5 \leftrightarrow \theta^T x^i \geq 0$ .
- Se  $\theta^T x^i \gg 0$  então temos alta confiança que  $y^i = 1$  enquanto se  $\theta^T x^i \ll 0$  temos alta confiança que  $y^i = 0$ .
- Podemos dizer assim que o hiperplano  $\theta^T x = 0$  é um hiperplano separador para as duas classes.

# Margens



- Primeiro vamos considerar que  $y^i \in \{-1, +1\}$ .
- Dado um exemplo  $(x^i, y^i)$ , vamos definir uma margem funcional de  $(w, b)$  com relação ao exemplo o valor  $\gamma^i = y^i(w^T x^i + b)$
- Se  $y^i = 1$  então queremos que o valor da margem seja positivo, enquanto se  $y^i = -1$  queremos o valor da margem negativo.
- Restrição:  $y^i(w^T x^i + b) \geq 0$

# Margens geométricas



# Normalização da margem

- Normalização da margem ( $w, b$ ):

$$w^T \left( x^i - \gamma^i \frac{w}{\|w\|} \right) + b = 0$$

- Resolvendo para  $\gamma^i$  temos:

$$\gamma^i = y^i \left( \left( \frac{w}{\|w\|} \right) x^i \right) + \frac{b}{\|w\|}$$

- Menor margem é a medida de qualidade do modelo:

$$\gamma = \min_{i=1, \dots, m} y^i$$

# Problema de otimização

- Queremos maximizar a margem para aumentar a confiança do modelo:

$$\begin{aligned} \max_{\gamma, w, b} \quad & \gamma \\ \text{s.a.} \quad & y^i(w^T x^i + b) \geq \gamma \quad i = 1, \dots, m \\ & \|w\| = 1 \end{aligned}$$

- Podemos utilizar a relação entre  $\gamma$  e  $\|w\|$  para reescrever o problema de uma outra forma:

$$\begin{aligned} \max_{\gamma, w, b} \quad & \frac{\hat{\gamma}}{\|w\|} \\ \text{s.a.} \quad & y^i(w^T x^i + b) \geq \hat{\gamma} \quad i = 1, \dots, m \end{aligned}$$



- Fazendo  $\hat{\gamma} = 1$  chegamos na minimização de  $\|w\|$ :

$$\min_{w,b} \frac{1}{2} \|w\|^2$$
$$y^i(w^T x^i + b) \geq 1 \quad i = 1, \dots, m$$

- Problema de otimização não linear (quadrático)
- Técnicas consolidadas para resolvê-lo, incluindo a decomposição lagrangeana.

# Decomposição Lagrangeana

- Dado um problema de otimização qualquer:

$$\begin{aligned} \min_w \quad & f(w) \\ \text{s.a : } \quad & g_i(w) \leq 0 & i = 1, \dots, k \\ & h_i(w) = 0 & i = 1, \dots, l \end{aligned}$$

- Definimos o dual Lagrangeano como a função:

$$\mathcal{L}(w, \alpha, \beta) = f(w) + \sum_{i=1}^k \alpha_i g_i(w) + \sum_{i=1}^l \beta_i h_i(w)$$

onde  $\alpha$  e  $\beta$  são chamados multiplicadores de Lagrange.

# Decomposição Lagrangeana

- Considere, para um  $w$  fixo o valor:

$$\theta(w) = \max_{\alpha \geq 0, \beta} f(w) + \sum_{i=1}^k \alpha_i g_i(w) + \sum_{i=1}^l \beta_i h_i(w)$$

- Otimizando em  $w$  temos:

$$\min_w \theta(w) = \min_w \max_{\alpha \geq 0, \beta} \mathcal{L}(w, \alpha, \beta)$$

- Sob certas condições (funções  $g$  são convexas e funções  $h$  são afins), o problema acima é equivalente a:

$$\max_{\alpha \geq 0, \beta} \min_w \mathcal{L}(w, \alpha, \beta)$$

# Condições de Karush-Khan-Tucker (KKT)

- Para encontrar um trio  $(w^*, \alpha^*, \beta^*)$  ótimo é necessário e suficiente que satisfaça:

$$\frac{d}{dw_i} \mathcal{L}(w^*, \alpha^*, \beta^*) = 0 \quad i = 1, \dots, n \quad (1)$$

$$\frac{d}{d\beta_i} \mathcal{L}(w^*, \alpha^*, \beta^*) = 0, \quad i = 1, \dots, l \quad (2)$$

$$\alpha_i^* (g_i(w^*)) = 0, \quad i = 1, \dots, k \quad (3)$$

$$g_i(w^*) \leq 0, \quad i = 1, \dots, k \quad (4)$$

$$\alpha_i^* \geq 0, \quad i = 1, \dots, k \quad (5)$$

## Aplicando no modelo SVM

- Relembrando o modelo:

$$\min_{w,b} \frac{1}{2} \|w\|^2$$
$$y^i(w^T x^i + b) \geq 1 \quad i = 1, \dots, m$$

- Portanto:

$$f(w, b) = \frac{1}{2} \|w\|^2$$
$$g_i(w, b) = 1 - y^i(w^T x^i + b)$$

- A função Lagrangeana é então:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^m \alpha_i \cdot (y^i(w^T x^i + b) - 1)$$

## Observando as condições de KKT

- Primeiramente derivando em relação a  $w$ :

$$\nabla_w \mathcal{L}(w, b, \alpha) = w - \sum_{i=1}^m \alpha_i y^i x^i = 0$$

- Portanto:

$$w = \sum_{i=1}^m \alpha_i y^i x^i$$

- Agora derivando em relação a  $b$ :

$$\frac{d}{db} \mathcal{L}(w, b, \alpha) = \sum_{i=1}^m \alpha_i y^i = 0$$

## Utilizando as condições de KKT para voltar ao modelo

- Vamos inserir os resultados anteriores para eliminar os fatos  $w$  e  $b$ :

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^m \alpha_i \cdot \left( y^i (w^T x^i + b) - 1 \right)$$

- Usando o fato  $w = \sum_{i=1}^m \alpha_i y^i x^i$ :

$$\mathcal{L}(w, b, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m y^i y^j \alpha_i \alpha_j (x^i)^T x^j - b \sum_{i=1}^m \alpha_i y^i$$

- Agora sabendo que  $\sum_{i=1}^m \alpha_i y^i = 0$ :

$$\mathcal{L}(w, b, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m y^i y^j \alpha_i \alpha_j \langle x^i, x^j \rangle$$

- Chegamos a um modelo que depende apenas da variável lagrangeana  $\alpha$ :

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^m \sum_{j=1}^m y^i y^j \alpha_i \alpha_j \langle x^i, x^j \rangle$$

$$s.a : \alpha_i \geq 0, \quad i = 1, \dots, m \qquad \sum \alpha_i y^i = 0$$

- A partir do valor ótimo de  $\alpha$  para este modelo podemos reestabelecer os valores ótimos para  $w$  e  $b$ .